Project work computer vision: Super-Resolution mediante Autoencoder

Beatrice Laureti

Università degli studi di Ferrara

19 marzo 2026

Obiettivo

- Implementare un autoencoder per un task di Super-Resolution (SR): a partire da un'immagine a bassa risoluzione, si ricostruisce la corrispondente immagine originale ad alta risoluzione con la massima fedeltà possibile.

Dataset

Dataset: EuroSAT

- Contiene 27.000 immagini satellitari RGB con risoluzione spaziale di 10 metri per pixel.
- Le immagini hanno dimensione 64×64 pixel (ogni immagine copre un'area di circa 0.41 km^2 della superficie terrestre).
- Le immagini sono suddivise in 10 classi che rappresentano diverse tipologie di territorio.

Classi di EuroSAT

Istogramma di frequenza delle classi

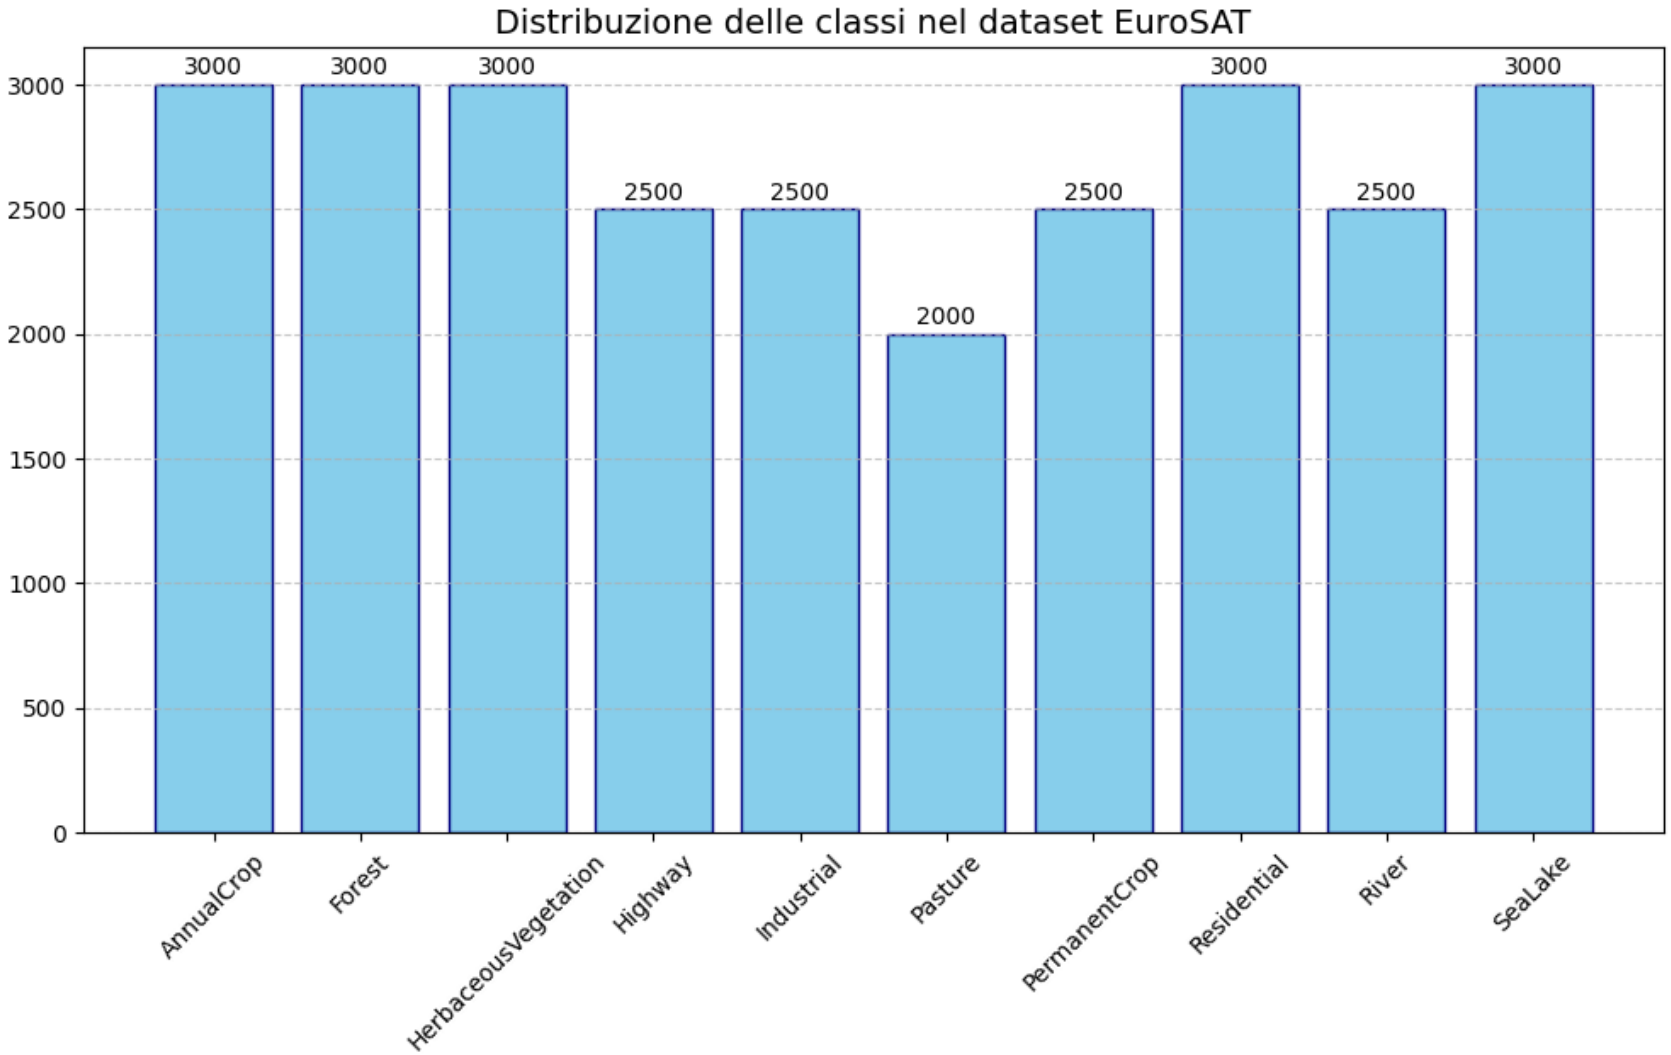

Loss e metriche utilizzate in SR

Loss

- **Mean Squared Error (MSE)**

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^{N} (x_i - \hat{x}_i)^2$$

Penalizza fortemente gli errori grandi. Ma tende a produrre immagini *over-smoothed*, con perdita di dettagli ad alta frequenza dove i bordi e i dettagli non sono nitidi.

- **L1 Loss (Mean Absolute Error)**

$$\mathcal{L}_{\text{L1}} = \frac{1}{N} \sum_{i=1}^{N} |x_i - \hat{x}_i|$$

Favorisce ricostruzioni più nitide e preserva meglio i bordi, risultando spesso preferibile in SR.

- **Charbonnier Loss**

$$\mathcal{L}_{\text{Charb}} = \frac{1}{N} \sum_{i=1}^{N} \sqrt{(x_i - \hat{x}_i)^2 + \varepsilon^2}$$

Molto utilizzata nei modelli moderni di SR poichè offre un buon compromesso tra MSE e L1. Combina stabilità numerica e robustezza, garantendo gradienti continui .

- **Perceptual Loss**

$$\mathcal{L}_{\text{perc}} = \sum_{l} \|\phi_l(x) - \phi_l(\hat{x})\|_2^2$$

  - ϕ_l è una rete neurale pre-addestrata (es. VGG) al livello l, $\phi_l(x)$ rappresenta le mappe delle caratteristiche (bordi, texture, forme) che vede al livello l quando guarda l'immagine originale.

Il confronto non avviene sui singoli pixel, ma sulle caratteristiche (feature) estratte dalla rete, permettendo di ricostruire immagini più realistiche e dettagliate.

Metriche

- **Peak Signal-to-Noise Ratio:** $\mathrm{PSNR} = 10 \log_{10}\left(\frac{MAX^2}{\mathrm{MSE}}\right)$
  - MAX: valore massimo possibile del pixel
  - MSE: errore quadratico medio pixel-wise
  - Il logaritmo comprime la scala e rende confrontabili grandi variazioni di errore
- Misura quanto il segnale ricostruito si discosta dall'originale in termini di errore medio sui pixel. Valori più alti indicano minore errore.
- È semplice da calcolare, ma valuta solo differenze pixel-wise tra immagine ricostruite e originale, risultando poco sensibile alla percezione visiva e alle strutture locali.
  - $<$ 25 dB: qualità bassa
  - 25–30 dB: qualità accettabile
  - 30–35 dB: buona qualità
  - $>$ 35 dB: alta qualità

- **Structural Similarity Index Measure:**

$$\mathrm{SSIM}(x, \hat{x}) = \frac{(2\mu_x\mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + C_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)}$$

  - $\mu_x, \mu_{\hat{x}}$: media locale (luminanza)
  - $\sigma_x, \sigma_{\hat{x}}$: deviazione standard (contrasto)
  - $\sigma_{x\hat{x}}$: covarianza (struttura condivisa)
  - C_1, C_2: costanti di stabilizzazione numerica

- Confronta immagini in termini di luminanza, contrasto e struttura. È più coerente con la percezione umana e più affidabile per valutare la qualità strutturale delle immagini ricostruite e del mantenimento dei dettagli.

  - < 0.80: scarsa preservazione strutturale
  - 0.80–0.90: buona qualità
  - 0.90–0.95: qualità elevata
  - > 0.95: qualità molto elevata

Implementazione reti

Struttura generica AutoEncoder per SR

- **Input a bassa risoluzione (LR):** l'autoencoder riceve un'immagine degradata (16×16 o 32×32) come punto di partenza.
- **Architettura asimmetrica dell'autoencoder:**
  - **Encoder:** una serie di convoluzioni estrae feature mantenendo la risoluzione spaziale; a differenza degli autoencoder classici, non si comprime ulteriormente l'immagine per non perdere informazioni essenziali.
  - **Bottleneck:** rappresentazione intermedia ricca di informazioni, che codifica contorni, pattern e texture utili alla ricostruzione.
  - **Decoder:** espande progressivamente la risoluzione tramite tecniche di upsampling (es. bilinear, transposed convolution, pixel shuffle) fino alla dimensione desiderata (HR).
- **Output ad alta risoluzione (HR):** l'AE produce una versione ad alta risoluzione dell'immagine, migliorando la nitidezza e la struttura rispetto all'input.

Skip connection

- Collegano direttamente l'input a bassa risoluzione (LR) o feature intermedie dell'encoder all'output del decoder.
- L'immagine LR (upsampled) viene sommata all'output del decoder per facilitare l'apprendimento dei dettagli ad alta frequenza.
- Riduce il rischio di vanishing gradient e accelera la convergenza durante l'addestramento.
- Permette alla rete di concentrarsi sulle differenze locali tra LR e HR, quindi impara a predire solo i residui (dettagli fini) invece di dover ricostruire l'intera immagine da zero.

Considerazioni generali

- Le prestazioni del modello dipendono in modo significativo dalla risoluzione dell'immagine di input: sono state analizzate le configurazioni 32×32 e 16×16, che richiedono architetture differenti e portano a risultati diversi.
- Il dataset è complessivamente numeroso e ben bilanciato; tuttavia, nel caso di input a 16×16, per migliorare le prestazioni sulle classi più complesse sono state introdotte tecniche di **data augmentation** e l'uso di **weighted loss**.
- Il task di Super-Resolution risulta più critico per le classi caratterizzate da elevata complessità strutturale, con numerosi dettagli fini e bordi netti (es. *Residential* e *Industrial*).

Rete 1: Input 32×32

Architettura Autoencoder

- **Input:** immagine LR 32x32 (downsampling bicubico).
- **Encoder (feature extraction):**
  - Conv2d 3 $\rightarrow$ 32, ReLU
  - Conv2d 32 $\rightarrow$ 64, ReLU
  - Conv2d 64 $\rightarrow$ 128, ReLU (**bottleneck**)
- **Decoder (upsampling e ricostruzione):**
  - Upsample bilineare 2x (32x32 $\rightarrow$ 64x64)
  - Conv2d 128 $\rightarrow$ 64, ReLU
  - Conv2d 64 $\rightarrow$ 32, ReLU
  - Conv2d 32 $\rightarrow$ 3 (output RGB)
  - Sigmoid per normalizzare i valori.

  Per tutte le convoluzioni: Kernel 3×3 con padding 1 per mantenere le dimensioni spaziali e utilizzo di ReLU per introdurre non-linearità nell'estrazione delle feature.
- **Output:** immagine HR 64x64.

Training

- Split dataset: 70% - 20 % - 10 %
- Loss function: L1
- Ottimizzatore: Adam
- Scheduler: ReduceLROnPlateau (riduce il learning rate se la validation loss non migliora)
- Early stopping: ferma l'addestramento se non migliora più (previene l'overfitting)

Evoluzione delle metriche durante il training

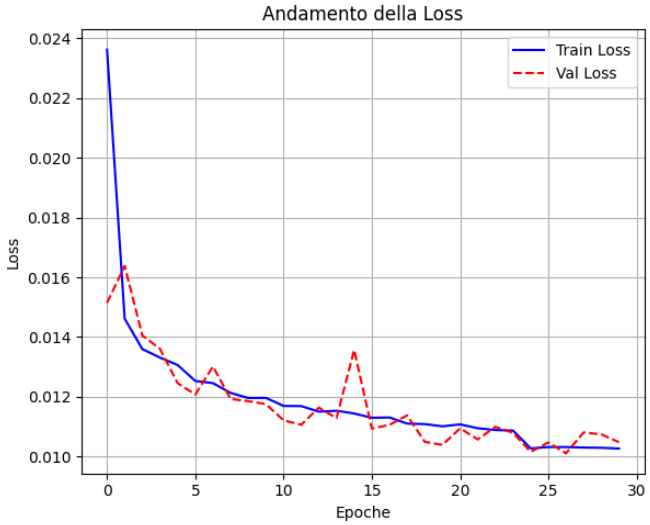

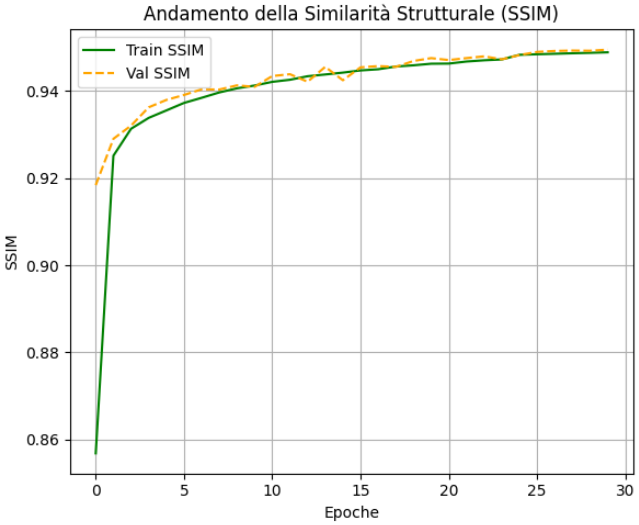

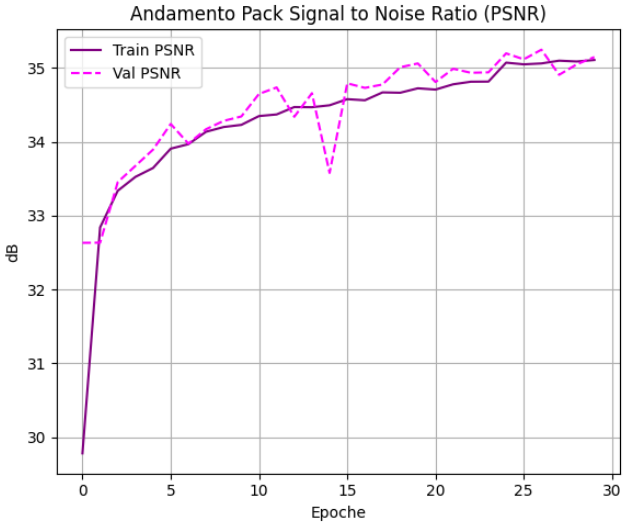

Epoca	Train Loss	Val Loss	Train SSIM	Val SSIM	Train PSNR	Val PSNR
1/40	0.023622	0.015143	0.8568	0.9184	29.78 dB	32.63 dB
30/40	0.010263	0.010476	0.9489	0.9495	35.11 dB	35.15 dB

Considerazioni sul training

- Il modello converge rapidamente nelle prime epoche, mostrando un miglioramento significativo sia in termini di Loss, SSIM e PSNR.
- Le prestazioni sul training e validation set risultano simili, indicando una buona capacità di generalizzazione e l'assenza di overfitting.

Risultati globali e per classe su test set

Classe	Campioni	Loss	SSIM	PSNR
Residential	314	0.022730	0.8637	30.70 dB
Industrial	257	0.022125	0.9205	29.94 dB
PermanentCrop	254	0.011804	0.9410	36.19 dB
HerbaceousVegetation	302	0.010253	0.9428	38.31 dB
Highway	269	0.010324	0.9525	37.02 dB
River	245	0.007772	0.9645	39.12 dB
Forest	297	0.005235	0.9677	43.59 dB
Pasture	187	0.005727	0.9704	42.05 dB
AnnualCrop	300	0.005836	0.9776	42.18 dB
SeaLake	275	0.003235	0.9923	47.49 dB
Media globale		**0.010691**	**0.9478**	**34.97 dB**

Visualizzazione ricostruzione immagine

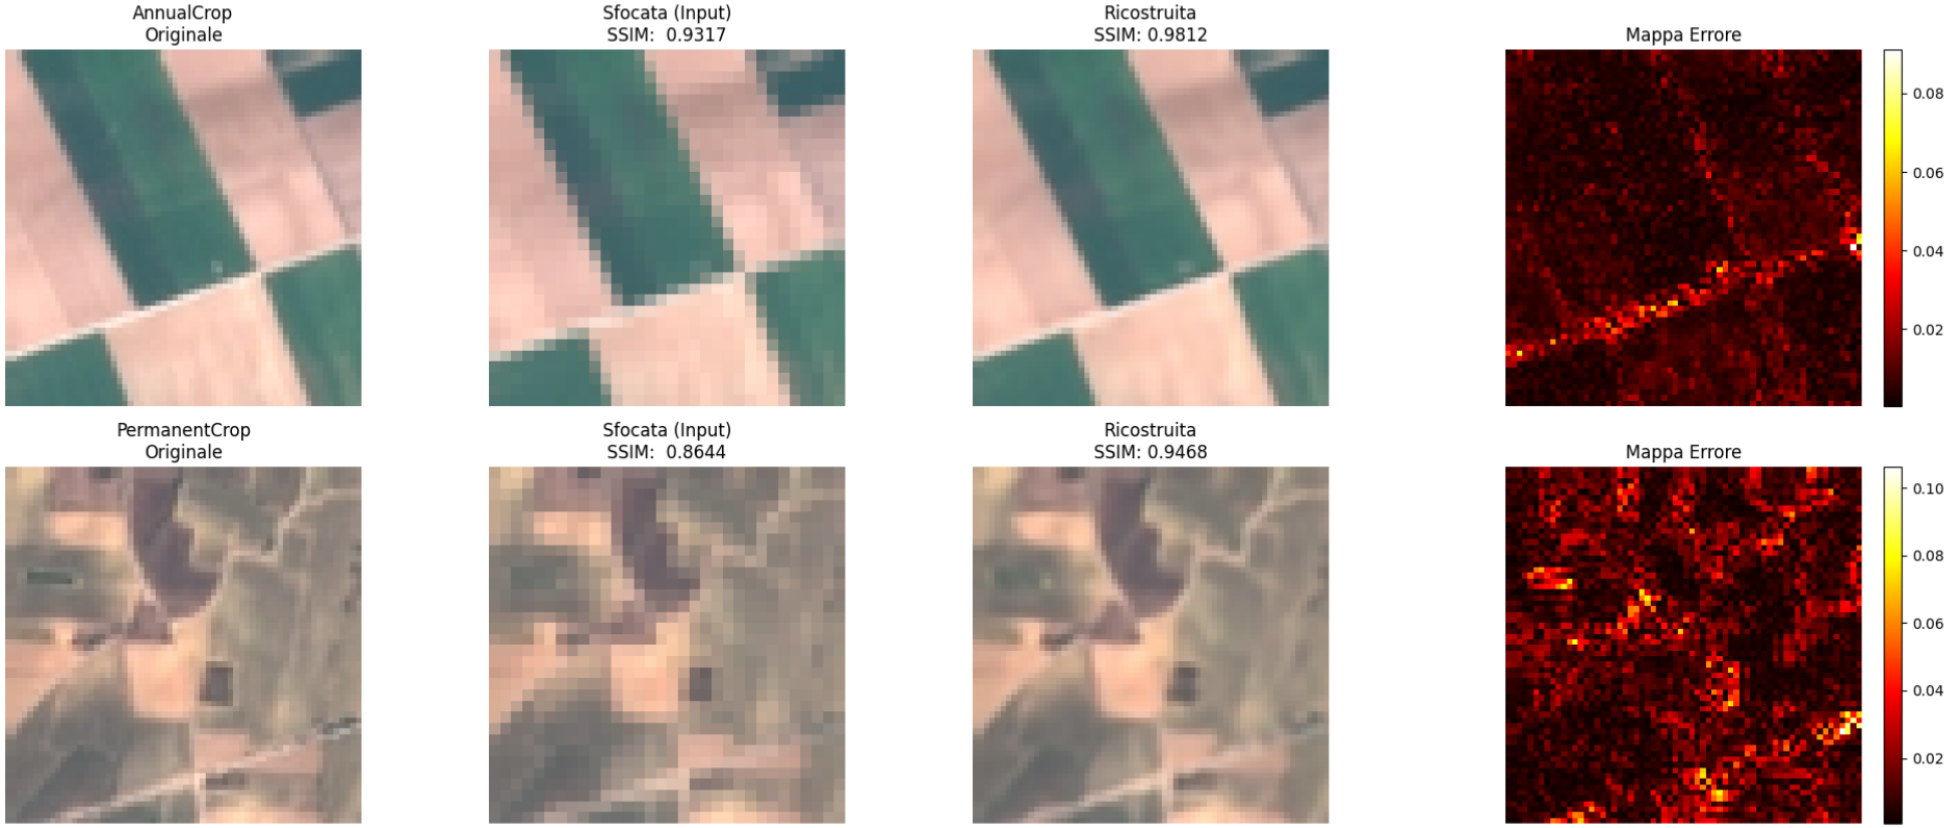

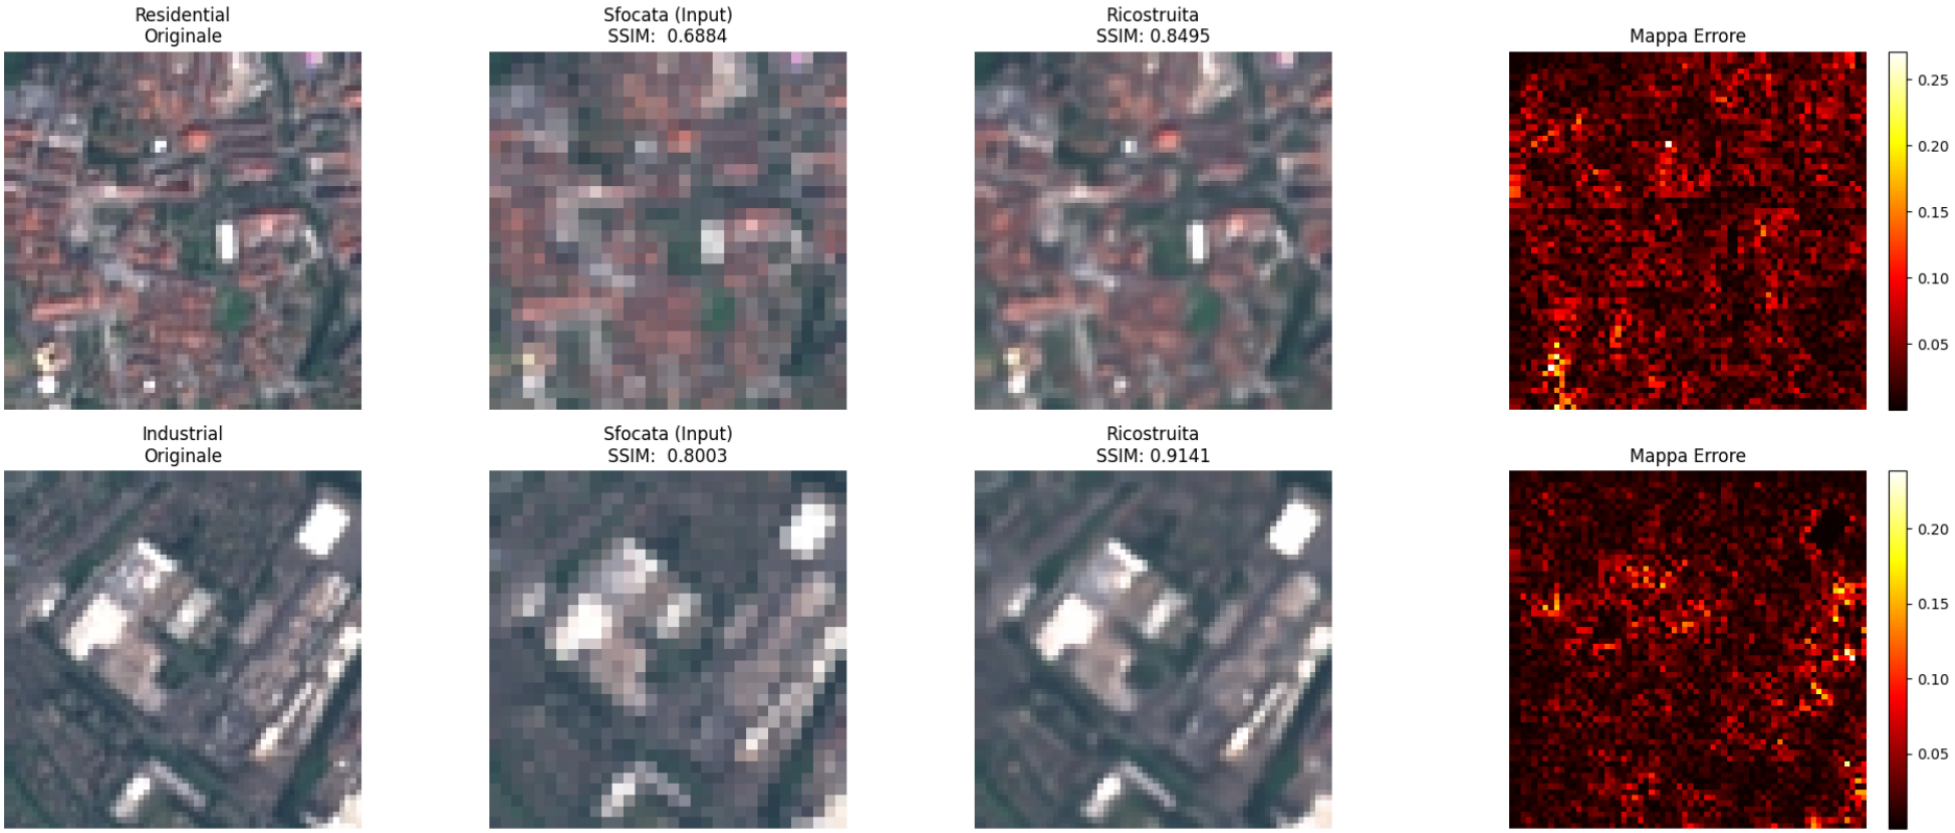
Residential
Originale
Sfocata (Input)
SSIM: 0.6884
Ricostruita
SSIM: 0.8495
Mappa Errore
0.25
0.20
0.15
0.10
0.05
Industrial
Originale
Sfocata (Input)
SSIM: 0.8003
Ricostruita
SSIM: 0.9141
Mappa Errore
0.20
0.15
0.10
0.05

Analisi dei risultati per classe

- Le prestazioni del modello non sono uniformi tra le diverse classi del dataset EuroSAT, evidenziando una forte dipendenza dalla complessità strutturale delle immagini.
  - Le classi *Residential* e *Industrial* presentano valori più bassi di SSIM e PSNR per l'elevata presenza di bordi netti, pattern geometrici e dettagli ad alta risoluzione che vengono persi durante il downsampling iniziale.
  - Le classi naturali come *Forest*, *Pasture*, *SeaLake* e *River* ottengono risultati migliori poichè presentano texture più omogenee e regolari.
- Questo comportamento è coerente con la natura del task di SR, che risulta più difficile in presenza di dettagli fini ad alta frequenza.
- Nel complesso, il modello riesce a ricostruire efficacemente le strutture globali dell'immagine, con maggiori difficoltà nelle classi caratterizzate da elevata complessità spaziale.

Rete 2: Input 16×16

Data Augmentation

- Sono state applicate trasformazioni geometriche come rotazioni a multipli di 90° e flip orizzontali poichè le immagini satellitari sono invarianti rispetto a tali trasformazioni.
- Sono state incrementate le classi a maggiore complessità strutturale per migliorarne la ricostruzione.

Classe	**Originale**	**Aumentato**	**Incremento**
AnnualCrop	2062	2062	1.0x
Forest	2127	2127	1.0x
HerbaceousVegetation	2097	2097	1.0x
Highway	1728	1728	1.0x
Industrial	1770	5310	3.0x
Pasture	1392	1392	1.0x
PermanentCrop	1733	3466	2.0x
Residential	2096	8384	4.0x
River	1743	1743	1.0x
SeaLake	2152	2152	1.0x

Istrogramma di frequenza classi dopo Data Augmentation

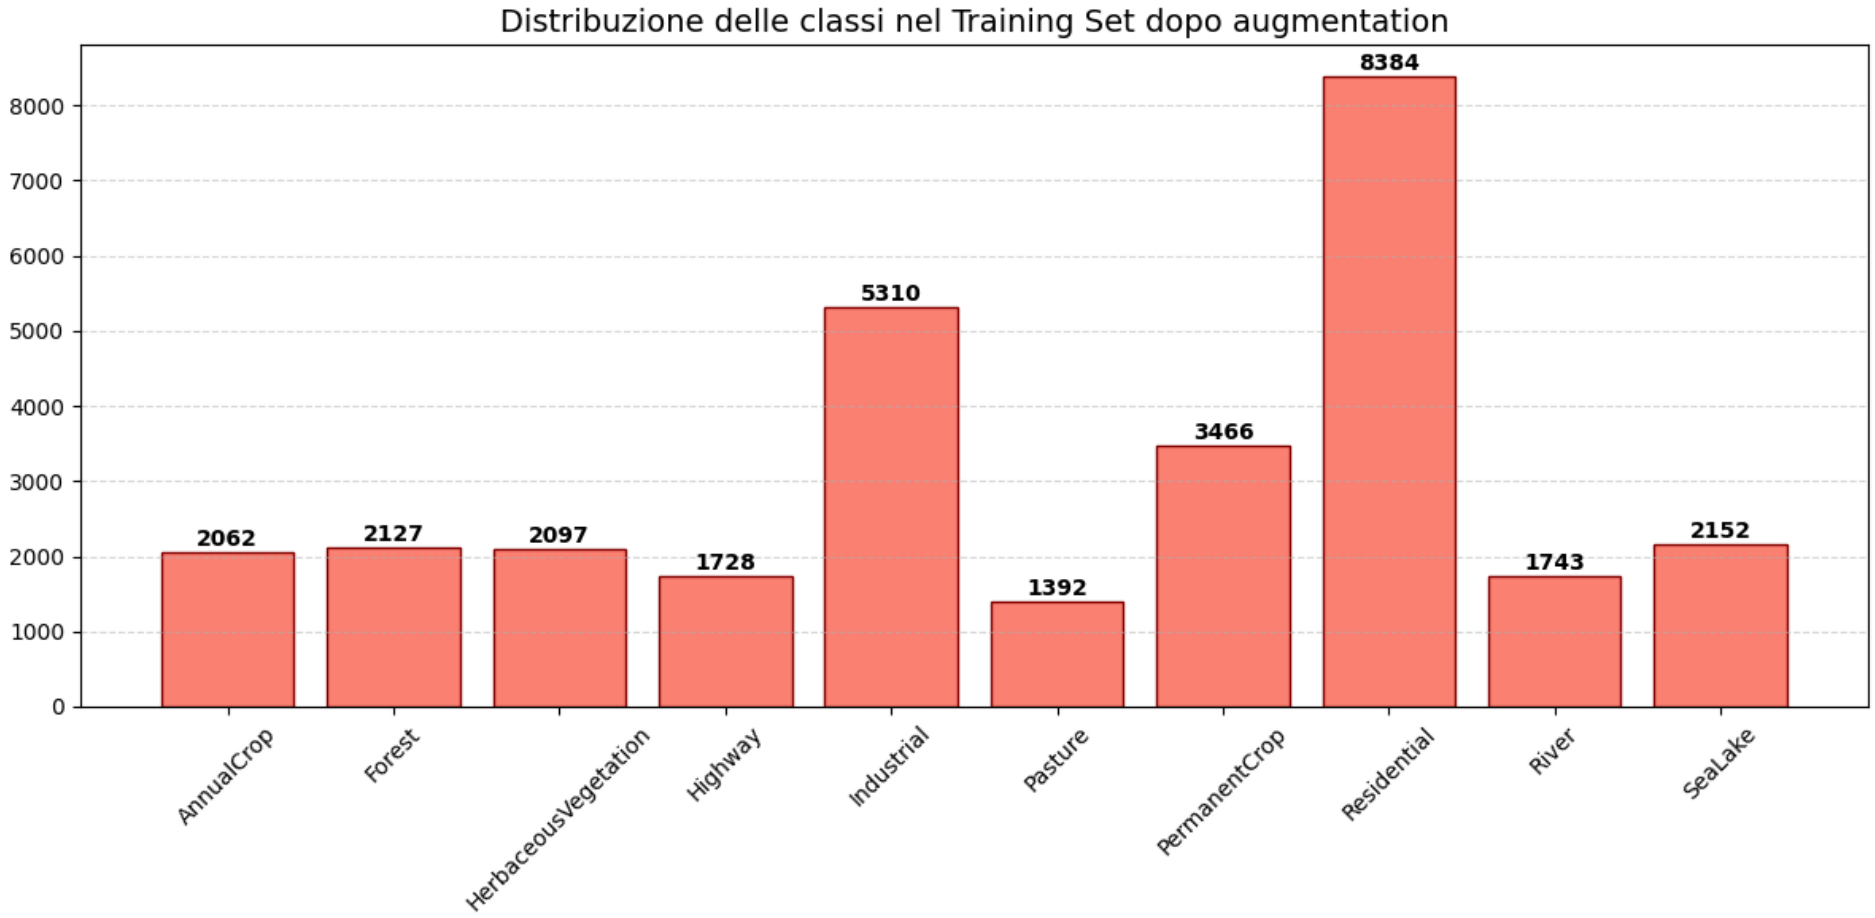

Architettura Autoencoder

- **Input:** immagine LR 16×16 (downsampling bicubico).
- **Encoder (feature extraction):**
  - Conv2d $3 \rightarrow 64$, ReLU
  - Conv2d $64 \rightarrow 128$, ReLU
  - Conv2d $128 \rightarrow 128$, ReLU (**bottleneck**)
- **Decoder (upsampling progressivo):**
  - Upsample bilineare 2x ($16 \times 16 \rightarrow 32 \times 32$)
  - Conv2d $128 \rightarrow 64$, ReLU
  - Upsample bilineare 2x ($32 \times 32 \rightarrow 64 \times 64$)
  - Conv2d $64 \rightarrow 64$, ReLU
  - Conv2d $64 \rightarrow 3$ per la ricostruzione dei canali RGB.
  - Clamp per avere valori in [0,1]
- **Skip Connection:**
  - L'input 16×16 viene interpolato bilinearmente a 64×64 e sommato all'output del decoder.
  - La rete apprende solo il residuo (dettagli fini e bordi), mentre la struttura globale è preservata dall'input upsamplato.

Training

- Split dataset: 70% - 20 % - 10 %
- Loss function: Charbonnier
- Weighted loss (pesi: Residential = 3, Industrial= 2.5, PermanentCrop=1.4)
- Ottimizzatore: Adam
- Scheduler: ReduceLROnPlateau (riduce il learning rate se la validation loss non migliora)
- Early stopping: ferma l'addestramento se non migliora più (previene l'overfitting)

Evoluzione delle metriche durante il training

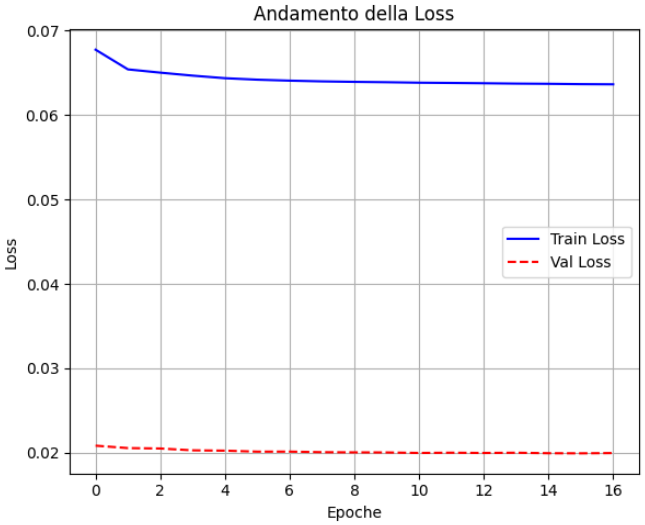

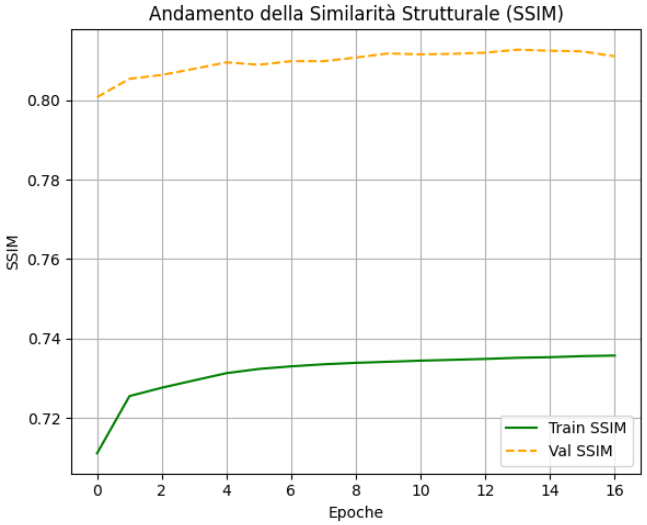

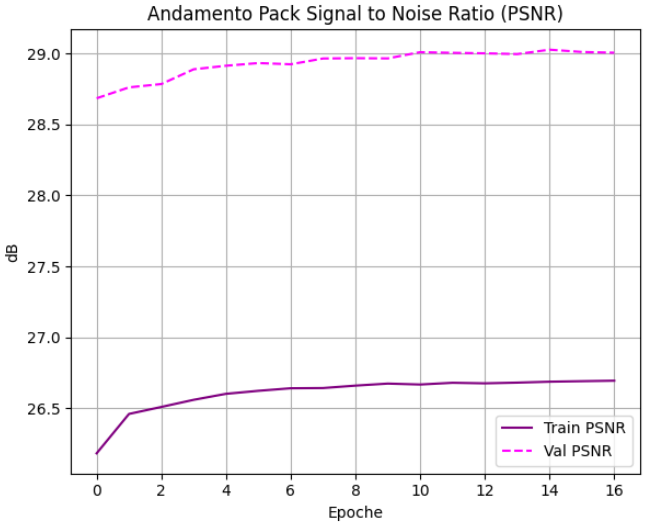

Epoca	Train Loss	Val Loss	Train SSIM	Val SSIM	Train PSNR	Val PSNR
1/40	0.067754	0.020843	0.7112	0.8007	26.18 dB	28.68 dB
17/40	0.063651	0.019970	0.7358	0.8110	26.70 dB	29.00 dB

Considerazioni sul training

- La loss decresce molto lentamente nel corso delle epoche, suggerendo che il modello fatica ad apprendere ulteriori informazioni utili per il task di SR.
- Sebbene sia presente un miglioramento rispetto alle prime epoche, l'incremento delle prestazioni risulta molto limitato, indicando una capacità modellistica insufficiente o una difficoltà intrinseca del task affrontato.
- La validation loss risulta significativamente più bassa della training loss poiché quest'ultima è calcolata utilizzando una loss pesata, mentre la validation è valutata con una loss non pesata.

Risultati globali e per classe su test set

Classe	Campioni	Loss	SSIM	PSNR
Residential	314	0.039888	0.5484	25.76 dB
Industrial	257	0.046348	0.6593	23.46 dB
PermanentCrop	254	0.025000	0.7473	29.62 dB
HerbaceousVegetation	302	0.019645	0.7920	32.92 dB
Highway	269	0.021332	0.7994	30.57 dB
River	245	0.015346	0.8533	32.79 dB
Pasture	187	0.010287	0.8891	36.66 dB
AnnualCrop	300	0.011867	0.9054	35.50 dB
Forest	297	0.007102	0.9251	40.85 dB
SeaLake	275	0.003493	0.9818	47.42 dB
Media globale		**0.020285**	**0.8064**	**28.89 dB**

Visualizzazione ricostruzione immagine

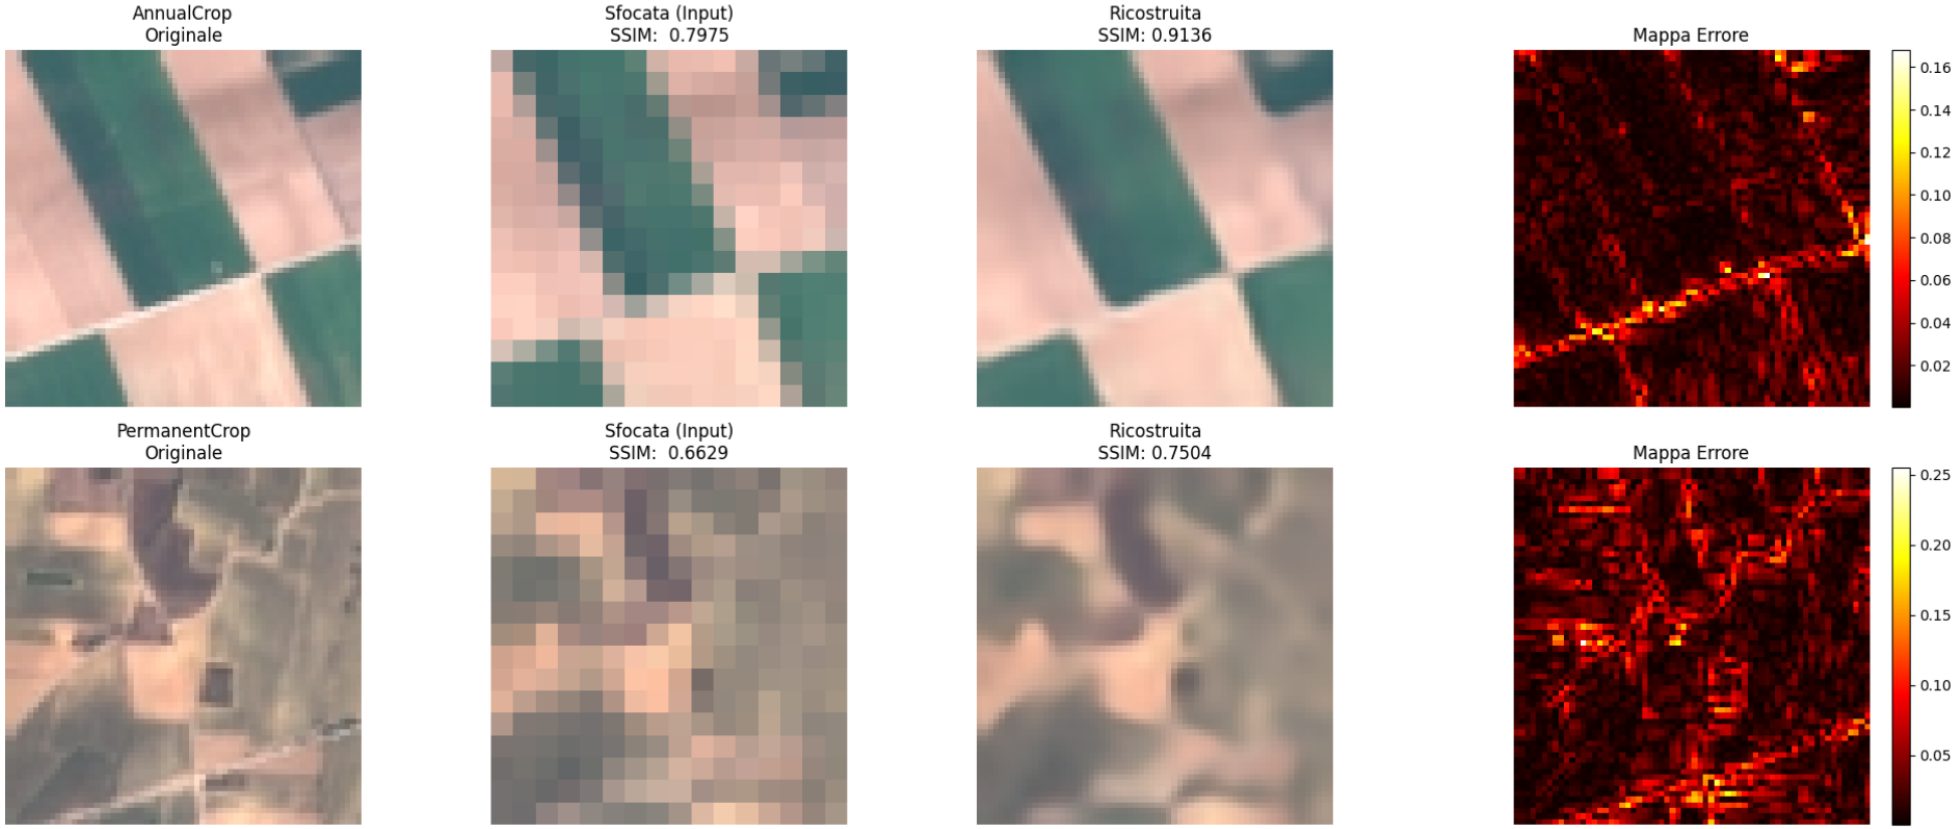

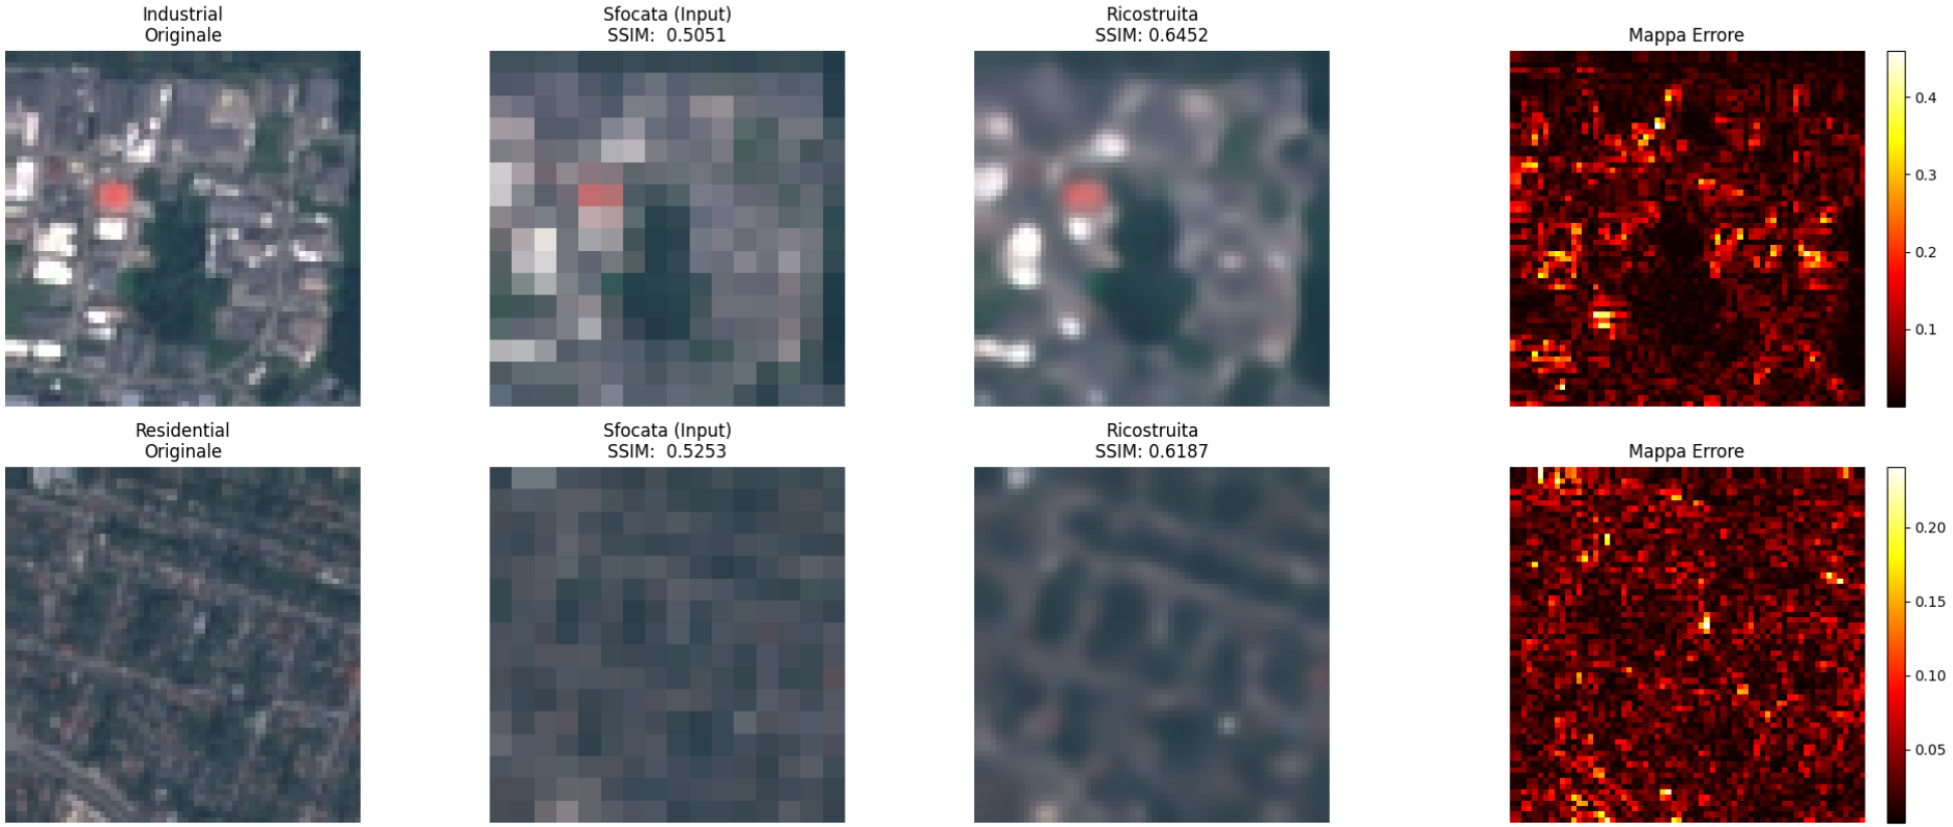
Industrial
Originale
Sfocata (Input)
SSIM: 0.5051
Ricostruita
SSIM: 0.6452
Mappa Errore
0.4
0.3
0.2
0.1
Residential
Originale
Sfocata (Input)
SSIM: 0.5253
Ricostruita
SSIM: 0.6187
Mappa Errore
0.20
0.15
0.10
0.05

Analisi dei risultati per classe

- Le prestazioni del modello non sono uniformi tra le diverse classi del dataset, evidenziando una forte dipendenza dalla complessità strutturale delle immagini.
- La ridotta informazione disponibile in input limita fortemente le prestazioni del modello, rendendo il task di SR particolarmente complesso per le classi più difficili da ricostruire.
  Infatti, la rete riesce a ricostruire correttamente solo le classi più omogenee, mentre fallisce nel recupero di strutture e pattern complessi.

Rete 3: Input 16×16 con residual blocks

Data Augmentation

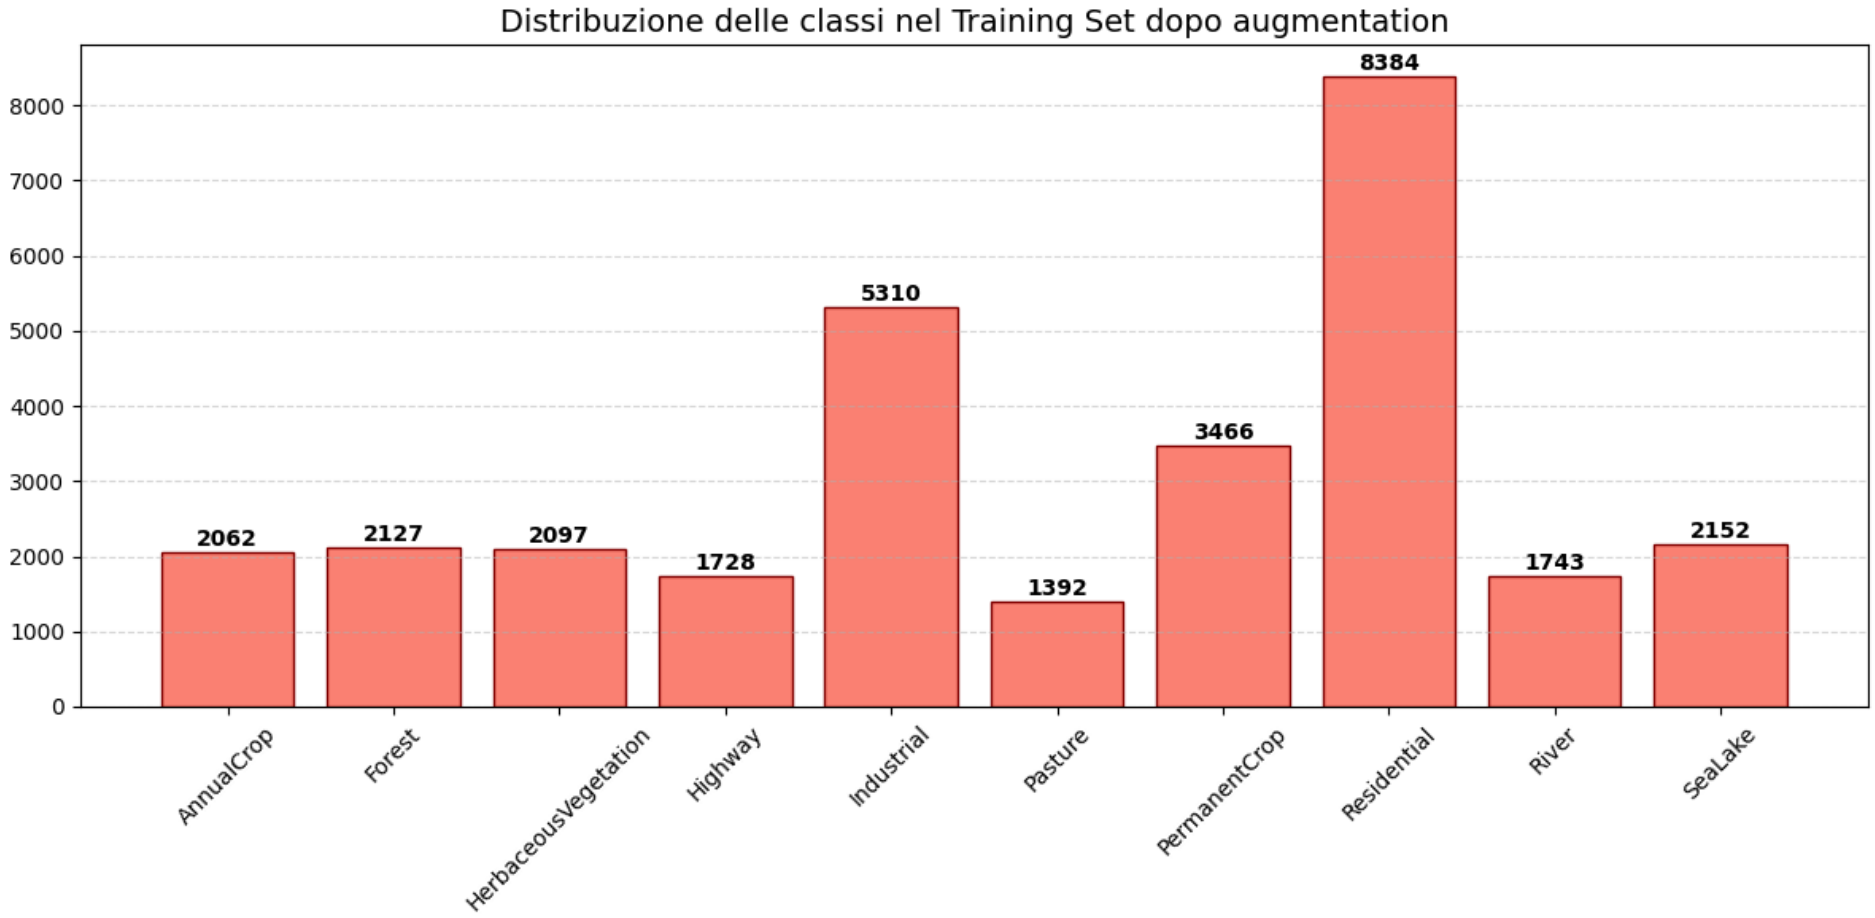

Architettura Autoencoder

- **Input:** Immagine LR 16×16 (downsampling bicubico).
- **Encoder (feature extraction):**
  - **Head:** Conv2d $3 \rightarrow 64$, kernel 3×3, ReLU.
  - **Residual Blocks (short skip connections):** catena di 4 blocchi residui (Conv2d $\rightarrow$ ReLU $\rightarrow$ Conv2d con somma residua).
  - **Long skip connection:** somma delle feature estratte dalla head con l'output dei blocchi residui.
- **Decoder (upsampling progressivo):**
  - Upsampling 1: Conv2d $64 \rightarrow 256$ + `PixelShuffle(2)` $\rightarrow 32 \times 32$.
  - Upsampling 2: Conv2d $64 \rightarrow 256$ + `PixelShuffle(2)` $\rightarrow 64 \times 64$.
  - Convoluzione finale: riduzione dei canali da 64 a 3 (RGB).
- **Global Skip Connection:** l'input 16×16 viene interpolato bilinearmente a 64×64 e sommato all'output del decoder. `torch.clamp` per avere valori in [0,1].
- **Output:** Immagine HR 64×64.

Utilizzo delle skip connection

- La rete invece di ricostruire l'immagine HR completa, impara solo la differenza tra l'immagine interpolata e quella reale.
- I blocchi residui con **short skip connection** facilitano l'addestramento di una rete più profonda, migliorando il flusso del gradiente e preservando le informazioni rilevanti.
- La **long skip connection** a bassa risoluzione consente di mantenere le feature globali estratte dalla head, evitando la perdita di informazione lungo la catena di blocchi residui.
- La **global skip connection** somma l'input interpolato all'output del decoder, delegando alla rete la ricostruzione dei soli dettagli fini e dei bordi.

Training

- Split dataset: 70% - 20 % - 10 %
- Loss function: Charbonnier $+ \lambda \cdot$ Perceptual Loss
- Weighted loss (pesi: Residential $= 3$, Industrial$= 2.5$, PermanentCrop$=1.4$)
- Ottimizzatore: Adam
- Scheduler: ReduceLROnPlateau (riduce il learning rate se la validation loss non migliora)
- Early stopping: ferma l'addestramento se non migliora più (previene l'overfitting)

Evoluzione delle metriche durante il training

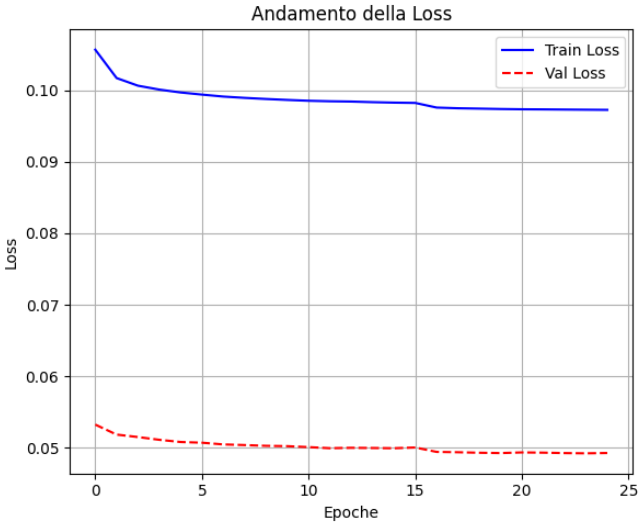

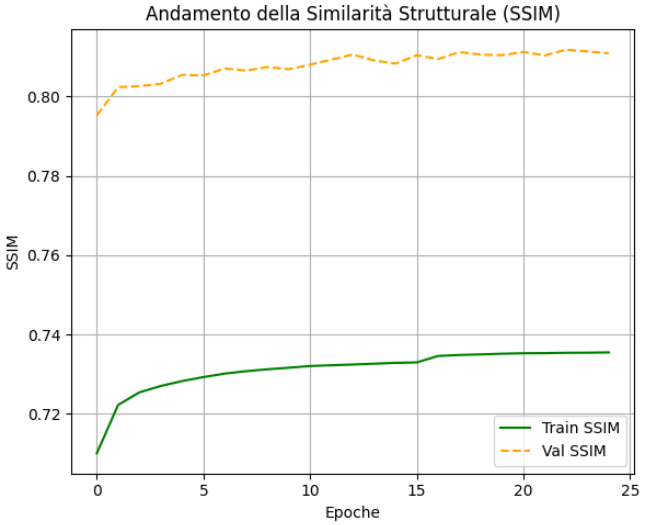

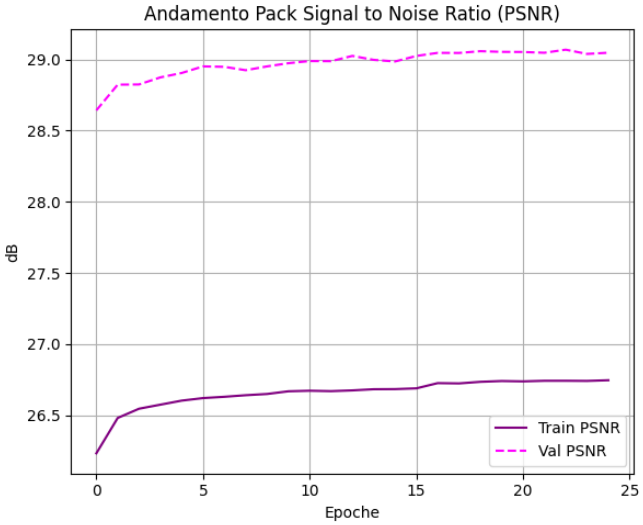

Epoca	Train Loss	Val Loss	Train SSIM	Val SSIM	Train PSNR	Val PSNR
1/40	0.105657	0.053259	0.7100	0.7952	26.23 dB	28.64 dB
25/40	0.097246	0.049290	0.7355	0.8109	26.75 dB	29.05 dB

Risultati globali e per classe su test set

Classe	Campioni	Loss	SSIM	PSNR
Residential	314	0.076254	0.5443	25.67 dB
Industrial	257	0.095599	0.6649	23.55 dB
PermanentCrop	254	0.066788	0.7489	29.66 dB
HerbaceousVegetation	302	0.048709	0.7825	32.64 dB
Highway	269	0.057147	0.8049	30.76 dB
River	245	0.044731	0.8590	33.01 dB
Pasture	187	0.037388	0.8886	36.65 dB
AnnualCrop	300	0.036737	0.9089	35.94 dB
Forest	297	0.023917	0.9191	40.47 dB
SeaLake	275	0.010064	0.9788	46.70 dB
Media Globale		**0.049778**	**0.8060**	**28.92 dB**

Visualizzazione ricostruzione immagine

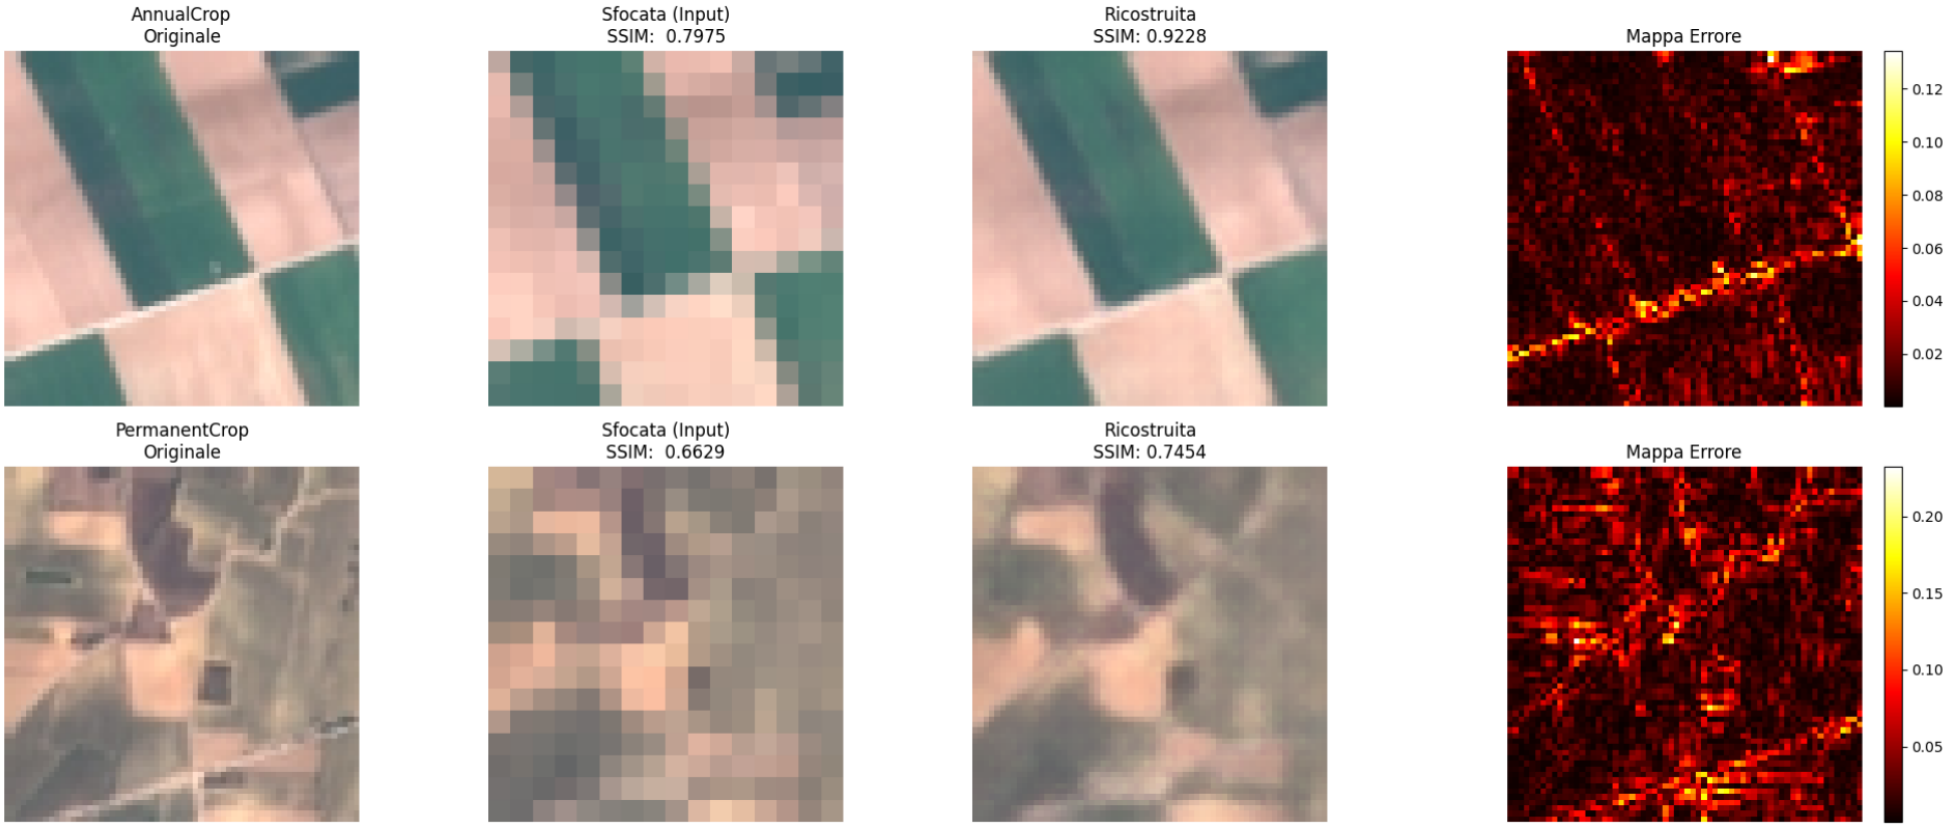

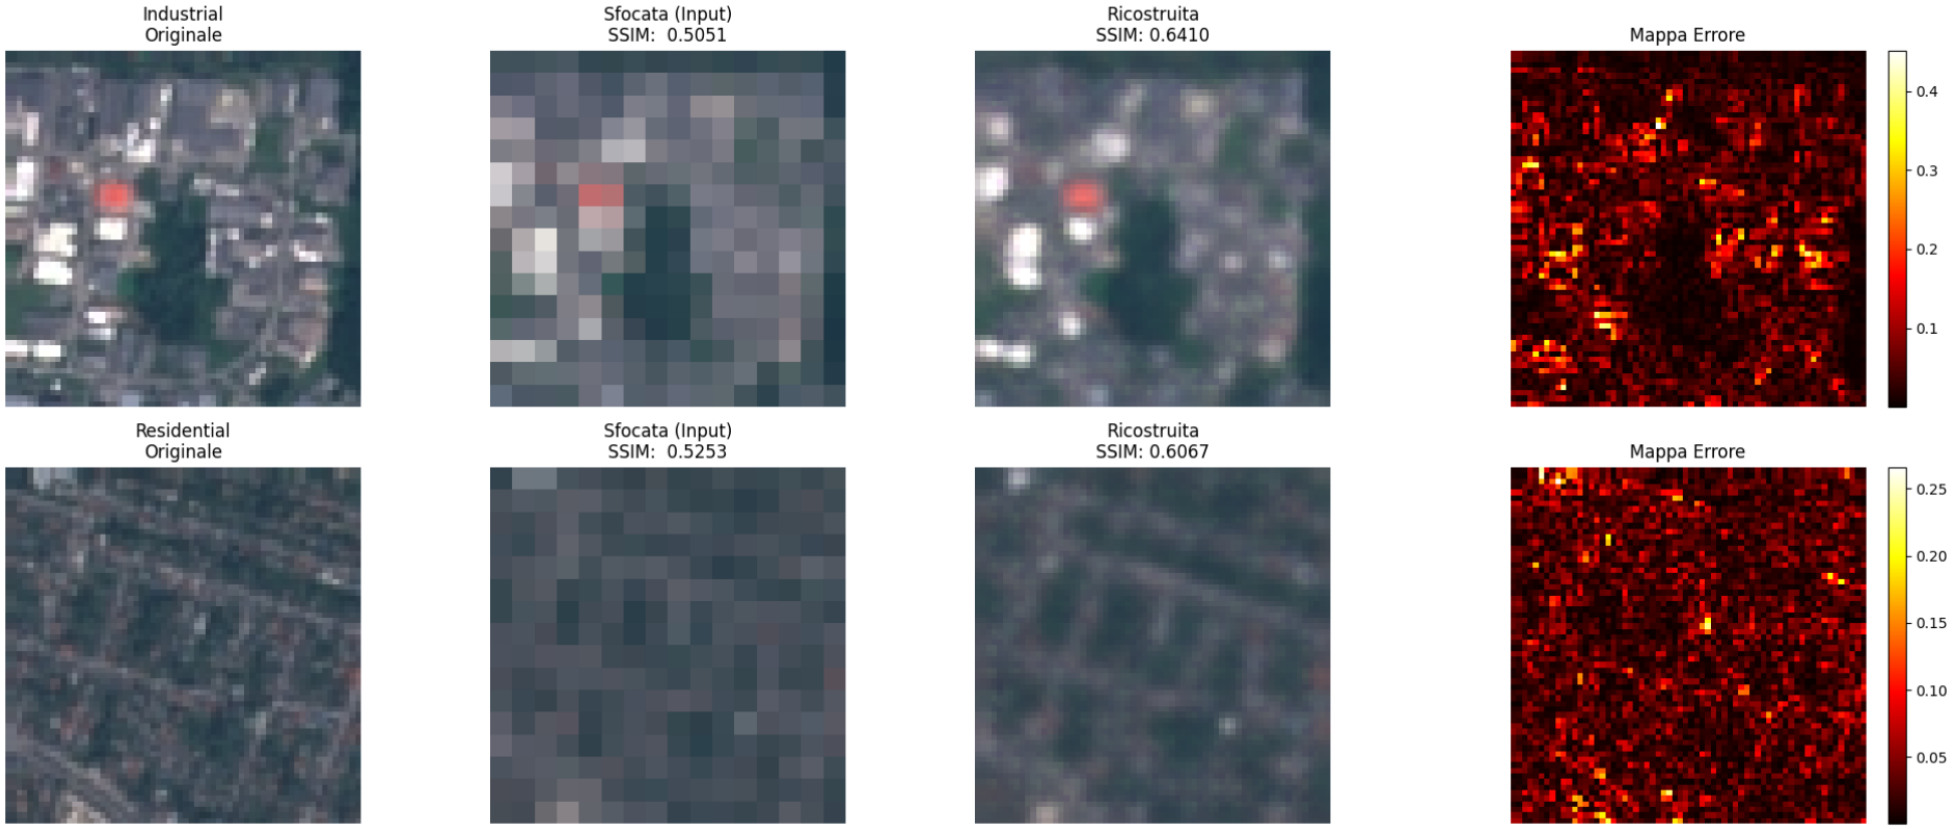
Industrial
Originale
Sfocata (Input)
SSIM: 0.5051
Ricostruita
SSIM: 0.6410
Mappa Errore
0.4
0.3
0.2
0.1
Residential
Originale
Sfocata (Input)
SSIM: 0.5253
Ricostruita
SSIM: 0.6067
Mappa Errore
0.25
0.20
0.15
0.10
0.05

Analisi dei risultati

- I risultati quantitativi ottenuti sono comparabili a quelli della Rete 2, sia considerando le metriche globali sia l'analisi per classe.
- L'uso della Perceptual Loss può introdurre artefatti o texture non realistiche, specialmente nelle aree strutturalmente complesse.

Considerazioni finali

Confronto risultati: rete 2 vs rete 3

- Anche applicando data augmentation e weighted loss, il miglioramento delle prestazioni delle due reti risulta contenuto. Senza queste tecniche i risultati sono leggermente peggiori, ma complessivamente simili, indicando che la difficoltà del task risiede nella risoluzione dell'input.
- L'introduzione di un'architettura più complessa (Rete 3) non comporta un miglioramento delle metriche, indicando che la forte perdita di informazione nell'immagine a bassa risoluzione rappresenta il limite principale del problema.
- A parità di prestazioni (SSIM e PSNR), l'architettura più semplice (Rete 2) risulta preferibile: richiede meno parametri, è più stabile durante l'addestramento e più facile da ottimizzare.

Considerazioni al variare della dimensione di input

- La difficoltà del task di SR dipende fortemente dalla risoluzione di input e dalla quantità di informazione disponibile.
- Nel caso di input **32×32**, l'immagine contiene il **25%** dei pixel dell'immagine originale 64×64, mentre nel caso di input **16×16** l'informazione originale scende al **6.25%**, con una perdita implicita di circa **93.75%** dei pixel originali.
- Questo spiega perché il task 16×16 → 64×64 risulti più complesso e perché, nonostante l'uso di tecniche per migliorare l'apprendimento (data augmentation, loss pesate, architetture più profonde), le classi ad alta complessità strutturale restino difficili da ricostruire.